



北方民族大学

本科毕业论文（设计）

题目： 基于 LangGraph 与 RAG 的医疗智能体
构建与实现

学院名称:	数学与信息科学学院
专 业:	数据科学与大数据技术
学 生 姓 名:	王石林
学 号:	20224522
校内指导教师:	常霞
校外指导教师:	无
论文提交时间:	2026 年 04 月 29 日

北方民族大学毕业论文（设计）诚信承诺书

学生姓名	王石林	年级	2022 级
所学专业	数据科学与大数据技术	学号	20224522
所在学院	数学与信息科学学院		

本人郑重承诺和声明：

所呈交的毕业论文（设计）《基于 LangGraph 与 RAG 的医疗智能体构建与实现》是本人严格遵守学校和学院有关规定，在指导教师的指导下独立完成的。毕业论文（设计）开展过程中未有弄虚作假、请人代做、抄袭他人成果等学术不端行为；文中所有引文或引用数据、图表均注解并说明来源，本人愿意为由此引起的后果承担责任。

学生（签名）：王石林

2026 年 05 月 02 日

教务处

基于 LangGraph 与 RAG 的医疗智能体构建与实现

摘 要

本文面向中医药知识问答场景，设计并实现了一种基于 LangGraph 与检索增强生成（Retrieval-Augmented Generation, RAG）的医疗智能体系统。系统以《中国药典》2025 年版一部为核心知识来源，通过 MinerU 文本解析、正则表达式数据清洗，并依据字段结构进行字段级分块与 JSON 结构化存储，构建了中医药检索知识库。在此基础上，结合开源医疗问答数据和药典内容形成领域微调数据集，并采用 LoRA 微调方法对开源大语言模型进行中医药问答适配。在系统架构上，本文利用 LangGraph 将缓存查找、意图路由、查询改写、多策略检索、上下文组装、答案生成和流式输出等环节编排为统一状态图工作流，并通过 BM25、BGE-M3 向量检索与 RRF 融合策略提升知识召回效果。实验结果表明，LoRA 微调能够提高模型在医学问答任务中的准确率和领域表达能力，RAG 能够为回答提供外部知识依据并降低模型幻觉风险，LangGraph 状态图编排则增强了系统流程的可控性、可维护性和扩展性。最后，本文基于 Gradio 实现了中药知识问答原型界面，验证了系统在中医药知识查询中的可用性和交互友好性，并为后续安全增强、知识扩展和工程部署奠定基础。研究结果可为垂直领域医疗智能体和专业知识问答系统建设提供参考。

关键词：医疗智能体；LangGraph；检索增强生成；LoRA 微调；中医药问答

Construction and Implementation of a Medical Agent Based on LangGraph and RAG

Abstract

This paper addresses the scenario of traditional Chinese medicine (TCM) knowledge question-answering by designing and implementing a medical agent system based on LangGraph and Retrieval-Augmented Generation (RAG). The system uses the 2025 edition Part I of the China Pharmacopoeia as the core knowledge source, constructing a TCM retrieval knowledge base through MinerU text parsing, regular expression-based data cleaning, and field-level segmentation and JSON structured storage in accordance with the field structure. On this basis, it combines open-source medical question-answering data with pharmacopoeia content to form a domain-specific fine-tuning dataset, and employs the LoRA method to adapt large open-source language models for TCM question-answering tasks. Architecturally, this paper utilizes LangGraph to orchestrate operations such as cache lookups, intent routing, query rewriting, multi-strategy retrieval, context assembly, answer generation, and streaming output into a unified state graph workflow, while enhancing knowledge retrieval performance through a Reciprocal Rank Fusion (RRF) strategy that combines BM25 and BGE-M3 vector retrieval. Experimental results demonstrate that LoRA fine-tuning improves the model's accuracy and domain-specific expression capabilities in medical question-answering tasks, RAG provides external knowledge support for responses and reduces model hallucination risks, and LangGraph's state graph orchestration enhances the system's controllability, maintainability, and scalability. Finally, this paper implements a prototype interface for Chinese herbal medicine knowledge question-answering using Gradio, validating the system's usability and interaction friendliness for Chinese herbal medicine knowledge queries, while laying the foundation for future security enhancements, knowledge expansion, and engineering deployment. The findings offer a reference for developing medical agents and specialized knowledge question-answering systems in vertical domains.

Key Words: Medical Agent; LangGraph; Retrieval-Augmented Generation; LoRA Fine-tuning; Traditional Chinese Medicine Question Answering

目 录

摘 要	I
Abstract	II
第一章 绪 论	1
第二章 相关理论与技术基础	3
2.1 大语言模型与参数高效微调基础	3
2.2 检索增强生成与检索评测方法	5
2.3 LangGraph 框架与文本生成评估	9
第三章 数据集构建与预处理	13
3.1 数据来源	13
3.2 知识库构建与预处理	13
3.3 微调数据集构建	17
3.4 RAG 及大模型评测问答集设计	18
第四章 医疗大语言模型微调实验	21
4.1 基座模型选择	21
4.2 微调实验设置	21
4.3 微调效果评测	24
第五章 基于 LangGraph 与 RAG 的医疗智能体设计与实验	27
5.1 智能体总体架构设计	27
5.2 查询理解与意图分流	28
5.3 多策略检索设计与实验	30
5.4 模型接入与流式生成	31
5.5 幻觉现象检测与实验结果分析	32
第六章 中药知识问答原型系统界面设计与实现	35
6.1 Gradio 框架简介	35
6.2 系统界面设计与功能展示	35

第七章 总结与展望 37

 7.1 总结 37

 7.2 不足与展望 38

参考文献 39

致 谢 43

附录 45

第一章 绪 论

近年来，大语言模型（Large Language Model, LLM）在自然语言理解、文本生成、知识问答和智能对话等任务中表现出较强能力。Brown 等在 GPT-3 研究中指出，扩大语言模型规模能够显著提升模型在少样本任务中的泛化表现，为通用大语言模型进入复杂任务场景奠定了基础^[1]。在教育、医疗、金融和政务等垂直领域，大语言模型的应用价值不断显现。其中，医疗领域具有知识密集、专业性强、实际需求广泛等特点，对智能问答系统的准确性、规范性和可追溯性提出了更高要求，因此成为大语言模型落地应用的重要方向之一。

传统医疗问答系统多依赖规则模板、关键词检索或知识图谱，在结构化问题和固定问答场景中具有一定效果，但面对自然语言表达多样、问题意图复杂、知识关联度较高的场景时，容易出现理解能力不足、回答形式僵化和交互体验不佳等问题。Singhal 等对临床知识问答模型的研究表明，大语言模型虽然能够编码一定医学知识，但医疗场景仍需要更严格的事实准确性和安全性控制^[2]。同时，Ji 等在自然语言生成幻觉研究综述中指出，生成模型可能产生与事实不符或缺乏证据支撑的内容，这一问题在专业医疗问答中尤其需要被重点控制^[3]。因此，医疗智能体不仅需要具备自然语言交互能力，还需要能够接入权威知识库，使回答更加专业、可靠和可追溯。

中医药知识问答是医疗智能体应用中的重要方向。中医药知识体系内容丰富，涉及中药材、饮片、成方制剂、性味归经、功效主治、用法用量、注意事项和贮藏要求等多个方面，术语专业且字段结构明显。《中华人民共和国药典》2025 年版一部以规范字段收载中药材、饮片、植物油脂与提取物、成方制剂和单味制剂等内容，是本文构建中医药知识库的重要权威来源^[4]。普通用户在查询中药知识时，常常难以准确理解药材功效、禁忌和用法等内容；如果完全依赖模型自身记忆，又容易出现事实错误或表述不规范的问题。因此，结合药典等权威资料构建中医药知识库，并利用大语言模型进行自然语言问答，对于提高中医药知识获取效率、推动中医药知识服务智能化具有一定价值。

检索增强生成（Retrieval-Augmented Generation, RAG）技术为解决大语言模型知识不可靠问题提供了有效思路。Lewis 等提出的 RAG 方法将非参数化检索模块与生成模型结合，使模型在生成回答前先利用外部知识源检索相关文档，再基于检索结果进行回

答生成^[5]。与单纯依赖模型参数记忆相比，RAG 能够提高知识更新效率，增强回答依据的可追溯性，并在一定程度上降低幻觉生成风险。与此同时，Hu 等提出的 LoRA 方法通过低秩矩阵注入实现参数高效微调，能够在有限计算资源条件下对开源大语言模型进行垂直领域适配，使模型更好地理解 and 表达中医药专业知识^[6]。

医疗智能体的实现还需要流程控制能力。实际问答系统通常包含缓存查找、意图识别、查询改写、知识检索、上下文组装、答案生成、流式输出和结果展示等多个环节，若仅采用线性脚本组织流程，系统的可维护性和扩展性较弱。LangGraph 作为状态图式智能体编排框架，能够将复杂任务拆分为节点、边和条件分支，使医疗问答流程更加清晰、可控和易于扩展。因此，本文以“基于 LangGraph 与 RAG 的医疗智能体构建与实现”为研究主题，围绕中医药知识问答场景，综合药典知识库、检索增强生成、模型微调和智能体编排技术，设计并实现一个具有专业知识支撑和流程控制能力的医疗智能体系统。

本文研究具有一定理论意义和实践意义。本文将参数高效微调、检索增强生成和智能体流程编排结合起来，探索大语言模型在中医药知识问答场景中的系统化应用方法，关注外部知识库、检索策略、生成模型和评估指标之间的协同关系，有助于丰富垂直领域大语言模型应用研究。本文依据药典资料构建中医药知识库，并通过 RAG 提供可追溯的知识依据，通过 LoRA 微调提升模型对中医药问答任务的适应能力，通过 LangGraph 提高系统流程的稳定性和可维护性。研究成果可为中医药知识服务、医学知识学习辅助和垂直领域智能问答系统开发提供参考。

第二章 相关理论与技术基础

2.1 大语言模型与参数高效微调基础

本章围绕医疗智能体系统的核心技术栈，依次介绍大语言模型与参数高效微调、检索增强生成与检索评测方法，以及 LangGraph 框架与文本生成评估三个方面的基础理论。首先阐述 Transformer 架构及其自注意力机制，并引出 LoRA 参数高效微调方法的基本原理；随后介绍检索增强生成的整体架构，重点说明 BM25 稀疏检索、稠密向量检索与 RRF 融合策略，以及用于衡量检索效果的评测指标；最后介绍 LangGraph 状态图编排框架的核心概念，并给出大模型幻觉检测等指标的定义与计算方法。本章内容为后续数据构建、模型微调和智能体设计提供理论支撑。

一、Transformer 架构

Transformer 是当前大语言模型的主流基础架构，由 Vaswani 等人在 2017 年提出，完全基于自注意力机制而无需循环或卷积结构。其核心架构如图 2.1 所示^[7]。




图 2.1 Transformer 整体架构^[7]

自注意力机制是 Transformer 的核心创新，允许序列中任意位置的元素直接交互，一次计算即可捕获全局依赖关系，克服了循环神经网络中长距离信息传递效率低下的问题。单个注意力头的运算如公式(2-1)所示^[7]。

$$Attention(Q,K,V)=\text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V \quad (2-1)$$

其中 Q （查询）、 K （键）、 V （值）是由输入向量经不同线性变换得到， d_k 为键向量的维度，缩放因子 $\sqrt{d_k}$ 用于防止点积过大导致梯度不稳定。公式的核心操作是：先通过 Q 与 K 的点积计算序列内各位置间的原始相关性分数，形成注意力分数矩阵；再引入 softmax 函数对每一行进行归一化，将其转化为总和为 1 的概率分布，这一步骤不仅赋予了模型对不同位置的关注权重，更通过指数函数的放大效应，使其能聚焦于分数更高的关键位置。最后，用归一化后的权重对 V 进行加权求和，得到融合了全局上下文信息的输出表示。该机制允许序列中任意位置的元素直接交互，一次计算即可捕获全局依赖关系，克服了循环神经网络中长距离信息传递效率低下的问题。

为进一步增强模型的表示能力，Transformer 引入多头注意力机制，将多个不同参数化的注意力头并行计算后拼接输出，使模型能够在不同表示子空间中同时学习不同侧面的语义特征。由于自注意力机制本身不具备序列顺序感知能力，Transformer 通过注入旋转位置编码（RoPE）使模型获得序列的位置信息。

在多头注意力之后，每个 Transformer 层依次经过残差连接与层归一化，然后进入由两层线性变换和激活函数组成的前馈神经网络。残差连接有效缓解了深层网络中的梯度消失问题，使 Transformer 能够堆叠数十层仍保持稳定训练。基于这一架构，大语言模型通常在海量文本语料上进行自回归语言建模预训练，模型根据前文序列预测下一个词元，在这一过程中学习到丰富的语言知识与一定的推理能力。

二、参数高效微调

全量微调要求对预训练模型的所有参数进行梯度更新，当模型规模达到数十亿乃至数千亿参数时，训练所需的显存与计算资源变得极其高昂。参数高效微调旨在通过仅更新极少量参数，将大规模预训练模型适配至下游任务，在保持模型通用能力的同时大幅降低训练成本。

LoRA 的核心思想源于一个关键洞察：预训练模型在适配下游任务时，权重矩阵的更新量通常具有较低的内在秩。换言之，模型不需要在满秩空间中学习所有参数变化，而可以在一个低秩子空间内完成适配，其原理示意如图 2.2 所示。




图 2.2 LoRA 低秩适应原理示意图^[6]

基于这一假设，LoRA 将权重更新量 ΔW 显式分解为两个低秩矩阵的乘积^[6]，如公式 (2-2) 所示。

$$W' = W + \Delta W = W + BA \quad (2-2)$$

其中 $W \in \mathbf{R}^{d \times k}$ 为预训练权重矩阵，在微调过程中保持冻结，不参与梯度更新； $B \in \mathbf{R}^{d \times r}$ 与 $A \in \mathbf{R}^{r \times k}$ 为新引入的可训练低秩矩阵，秩 $r \ll \min(d, k)$ ，通常取值在 4 至 64 之间，优化低秩矩阵使得大幅减少了可训练参数量和显存占用。

在推理部署方面，LoRA 具备一项重要工程优势：训练完成后，可将低秩矩阵 BA 与原始权重 W 合并，即 $W'_{merged} = W + BA$ ，得到与原始模型完全相同结构和大小的权重文件。这意味着推理时无需额外计算分支，不引入任何推理延迟。此外，若要切换不同下游任务，只需更换对应的低秩矩阵，基座模型权重可共用，显著降低了多任务场景下的存储开销。

2.2 检索增强生成与检索评测方法

一、检索增强生成

大语言模型虽然在通用领域展现出强大的语言理解与生成能力，但在中医药等高度专业化的垂直领域中仍面临显著局限。模型的知识以参数化形式隐式存储于权重中，存在知识边界模糊、更新滞后和精确溯源困难等问题，导致其在面对知识盲区时可能产生幻觉，编造看似合理但事实错误的虚假信息。这一局限的根源在于大语言模型将知识记忆与语言生成耦合在同一参数空间中，过度的参数化使得知识更新与质量控制变得困难。因此，将外部知识引入生成过程，以非参数化的知识源弥补参数化知识的不足，成为提升模型专业问答能力的关键技术路径。

检索增强生成^[5]（Retrieval-Augmented Generation, RAG）由 Lewis 等人于 2020 年提出，其核心思想是将信息检索与大语言模型生成有机结合：在模型生成回答前，先从外部知识库中检索与用户问题相关的文档片段，以检索到的文档作为生成依据，再将检索结果与用户问题拼接为完整上下文，输入大语言模型生成最终回答。这一机制将“知识存储”从模型参数剥离至外部知识库，使模型从知识的“记忆者”转变为知识的“运用者”，从而在保持语言生成能力的同时获得对外部权威知识的访问能力。对于本文关注的中医药问答场景，RAG 能够将药典等权威知识源接入生成流程，回答的每一条事实陈述均可找到出处，在提升专业性的同时增强了可信度与可追溯性。RAG 系统的核心架构如图 2.3 所示。




图 2.3 RAG 系统核心架构示意图

二、文本检索方法

RAG 系统的检索环节负责从知识库中召回与用户查询相关的文档片段。根据检索原理的不同，文本检索方法可分为稀疏检索与稠密检索两大类，两者在召回特征上互补，通过倒数排序融合（RRF）策略可进一步提升检索质量。

BM25 是一种基于词频-逆文档频率的经典稀疏检索模型，其相关性得分计算公式(2-3)所示^[8]。

$$\text{BM25}(q,d)=\sum_{t\in q}\text{IDF}(t)\cdot\frac{f_{t,d}\cdot(k_1+1)}{f_{t,d}+k_1\cdot\left(1-b+b\cdot\frac{|d|}{\text{avgdl}}\right)} \quad (2-3)$$

其中 $f_{t,d}$ 为词项 t 在文档 d 中的词频， d 为文档长度， avgdl 为平均文档长度， k_1 和 b 为可调参数。BM25 的优势在于无需训练、检索速度快，对药材名、方剂名等专有名词的精确匹配效果显著。但其局限也较为明显：依赖精确词项匹配，无法处理同义词和近义表述。

稠密检索借助预训练的嵌入模型将文本映射到连续向量空间，通过计算查询向量与文档向量之间的余弦相似度来衡量语义相关性，公式(2-4)所示^[9]。

$$\text{cosine}(\vec{A},\vec{B})=\frac{\vec{A}\cdot\vec{B}}{\|\vec{A}\|\|\vec{B}\|} \quad (2-4)$$

其中 $\vec{A}\cdot\vec{B}$ 为两向量的点积， $\|\vec{A}\|$ 和 $\|\vec{B}\|$ 分别为两向量的模长。语义相近的文本在向量空间中距离较近，即使使用完全不同的词语表达也能被有效召回，从而弥补了 BM25 的不足。本文选用 BGE-M3^[10]作为嵌入模型，该模型支持中英文多语言编码，最大输入长度为 8192 tokens，能够有效处理药典文本的语义编码。稠密检索的双编码器架构如图 2.4 所示。




图 2.4 双编码器稠密检索架构图

倒数排序融合^[11]（RRF）是一种基于排名的融合算法，依据各检索器中文档的相对排序位置而非绝对分数计算融合得分。其核心优势在于绕过了不同检索器分数尺度不一致的问题——BM25 的得分范围受词频和文档长度影响，Embedding 的余弦相似度取值固定，两者分数不可直接线性相加。RRF 的计算公式如(2-5)所示。

$$RRF(d) = \sum_{\gamma \in R} \frac{1}{k + \text{rank}_{\gamma}(d)} \quad (2-5)$$

其中 R 为参与融合的检索器集合，本文中 $R = \{BM25, Embedding\}$ ； $\text{rank}_{\gamma}(d)$ 为文档 d 在检索器 γ 返回结果中的排名位置， k 为平滑常数，通常取 $k = 60$ ，最终按 RRF 得分降序排列，取前 k 条作为融合后的检索结果。

三、RAG 检索评测指标

检索质量的量化评测是 RAG 系统迭代优化的基础。从海量文档中精准定位相关知识片段，是 RAG 回答正确的前提，只有首先明确检索器在召回能力与排序精度上的表现，才能有针对性地改进检索策略与分块方案。给定用户查询 Query，检索器从知识库中返回 Top-K 文档列表，评测时将检索结果与标注的相关文档集合进行对比，通过衡量检索结果的命中情况、覆盖完整性和排序精度，可以诊断系统的检索能力短板并指导改进方向。本文采用命中率（Hit@K）、召回率（Recall@K）、平均倒数排名（MRR）和

归一化折损累计增益（ $nDCG@K$ ）这四项指标来评估命中能力、召回覆盖和排序质量等三个维度的检索性能。各指标的计算方式与含义如表 2.1 所示。

表 2.1 RAG 检索评测指标

指标	公式	说明
Hit@K	$Hit@K = (\text{命中至少 1 个相关文档的查询数}) \div (\text{总查询数})$	Top-K 结果中至少包含一个相关文档的查询比例，衡量检索成功率
Recall@K	$Recall@K = (\text{命中的相关文档数}) \div (\text{全部相关文档数})$	Top-K 结果覆盖了多少相关文档，衡量召回完整性
MRR	$MRR = [(1 \div \text{第 1 个查询的相关文档排名}) + \dots + (1 \div \text{第 K 个查询的相关文档排名})]$	排名越靠前贡献越高，衡量最佳匹配文档的排序位置，越接近 1 越好
$nDCG@K$	$nDCG@K = DCG@K \div IDC@K$	归一化排序质量指标，其中 $DCG@K$ 为折损累计增益， $IDC@K$ 为理想排序下的 $DCG@K$ 值

四项指标各有侧重：Hit@K 与 Recall@K 衡量检索覆盖能力，前者关注“是否命中”，后者关注“命中多少”；MRR 与 $nDCG@K$ 衡量排序精度，MRR 侧重首个相关文档的排位， $nDCG@K$ 全面评估所有相关文档的排序质量。四者联合使用构成互补的评测体系。

2.3 LangGraph 框架与文本生成评估

一、LangGraph 框架

LangGraph 是 LangChain 团队所推出的一个开源智能体编排框架^[12]，它的核心理念是把大语言模型驱动的应用程序抽象成有向状态图，借助节点、边以及条件的组合来达成复杂的多步推理以及自适应工作流，和传统那种把大语言模型调用串联在固定脚本里的做法不一样，LangGraph 把应用逻辑明确地建模为图结构，让流程控制、分支决策以及循环回退变成了一等设计要素。

LangGraph 主要由状态、节点以及边这三个要素组成，状态在整个图执行过程里是作为共享数据结构存在的，它承载着用户输入、中间结果以及流程控制标志等关键信息，节点属于基本执行单元，它可以封装大语言模型调用、数据库查询或者任意 Python 函数，借助统一接口接收当前状态并返回局部更新。边用来定义节点之间的流转方向，其中条件边可依据状态动态地选择下一个节点，循环边能让“执行—检查—回退重试”这种自适应回路得以实现，另外 LangGraph 支持把外部工具封装成节点，凭借“模型推理

“工具调用—结果反馈”这样的循环模式赋予大语言模型与搜索引擎、数据库、代码解释器等外部系统进行交互的能力，突破知识边界的限制。




图 2.5 LangGraph 状态图示例

引入 LangGraph 框架的目的在于更简便且高效地实现 RAG 系统的流程编排，构建功能更加强大的问答智能体。如图 2.5，系统可将缓存查找、意图路由、查询改写、多策略检索、检索重试、上下文组装、生成回答等节点组合为统一的状态图，方便丝滑地实现检索失败时的自动回退、敏感输入的硬拦截以及多轮对话的上下文管理等关键控制逻辑。

二、文本生成评估指标

大语言模型在生成回答时可能出现与事实不符或无法由外部证据支撑的内容，即幻觉现象。在医疗场景中，幻觉可能引发误导风险，因此需要对生成内容的事实准确性进行系统评估。

ROUGE-L^[13]和 BERTScore^[14]是通用的文本生成评测指标：前者基于最长公共子序列衡量生成文本与参考答案的表面重叠程度，后者基于 BERT 嵌入计算语义相似度，对同义表达具有更好的鲁棒性。两类指标能够反映回答的整体质量，但无法直接检测事实性错误或编造信息。针对幻觉检测，本文进一步引入以下三项指标：

Faith(忠实度)衡量生成回答是否严格基于给定的参考文档而非模型自身的参数化知识^[15]。其计算方式(2-6)为将回答分解为原子事实声明，逐一检测是否可在检索文档中找到支撑：

$$\text{Faith} = \frac{\text{被文档支撑的原子声明数}}{\text{生成回答中的原子声明总数}} \quad (2-6)$$

EntHit（实体命中率）从实体粒度评估幻觉，设生成回答中提取的实体集合为 E_{gen} ，检索文档中包含的实体集合为 E_{doc} ，则实体命中率定义为生成实体落在文档实体集中的比例公式如（2-7）：

$$\text{EntHit} = \frac{|E_{\text{gen}} \cap E_{\text{doc}}|}{|E_{\text{gen}}|} \quad (2-7)$$

Field（字段级事实准确率）基于药典的结构化字段进行细粒度评测，将回答涉及的命名字段逐一与知识源中同名字段比对，表述一致则记为正确，公式如（2-8）：

$$\text{Field} = \frac{\text{表述正确的字段数}}{\text{回答涉及的总字段数}} \quad (2-8)$$

Faith、EntHit 和 Field 三项指标从整体忠实度、关键实体和字段细节三个层次构成了中医药问答的幻觉评估体系，能够较全面地反映生成回答在事实层面的可靠性。

第三章 数据集构建与预处理

本章系统阐述本文所用数据集的来源、构建逻辑与预处理方法。首先介绍核心知识源《中国药典》一部的选取依据与知识贡献；其次详细说明面向 RAG 系统的知识库构建过程，包括药典文本解析、数据清洗以及数据分块与结构化；然后描述大语言模型微调的数据集构建方案，涵盖开源数据集的具体构成和基于药典的问答对生成方法；最后给出 RAG 评测问答集的设计思路与构建方法。

3.1 数据来源

本文以《中华人民共和国药典》2025 年版一部为核心数据源^[4]。该部收载中药材与饮片、植物油脂与提取物、成方制剂与单味制剂等品种约 3069 种，从人参、黄芪、当归等大宗常用药材到地方习用的特色民族药均有收录，品种层次的丰富性能够支撑各类中药知识查询需求。成方制剂部分涵盖六味地黄丸、桂枝汤类方等经典方剂，使数据源同时具备单味药与复方两个维度的知识储备。

全部品种遵循统一的编写体例，每个条目按品名、来源、性状、鉴别、检查、含量测定、性味与归经、功能与主治、用法与用量、注意、贮藏等固定字段组织，表述严谨、术语规范，具有药典级别的权威性和准确性。这一高度结构化的字段体系为后续知识库的字段级分块与 RAG 检索提供了天然的组织粒度，也为基于药典内容生成问答对奠定了格式基础。2025 年版在 2020 年版基础上新增了部分特色民族药品种并优化了饮片炮制规范，在保持体例延续性的同时反映了中药标准研究的最新进展。

3.2 知识库构建与预处理

知识库是 RAG 系统的核心基础设施，其构建质量直接影响检索召回率和最终生成回答的准确性。本文的 RAG 知识库完全基于《中国药典》一部构建，通过文本解析、数据清洗、数据分块与结构化三个步骤，形成高质量的检索知识单元。本节详述各处理环节的具体方法。

《中国药典》一部原始文本约 521.3 万字，以 PDF 格式存储，内容按层次化条目结构组织，每个品种以固定字段记录信息。本文采用 PDF 文档解析工具 MinerU^[16]对药典文本进行解析，该工具能够识别 PDF 中的文本块、标题层级和表格结构，将非结构化 PDF 转化为保留版面结构信息的 Markdown 格式文本。

药典中每个品种条目的字段均以“【】”括起的标准标题标识，主要包括【品名】、【来源】、【性状】、【鉴别】、【检查】、【含量测定】、【性味与归经】、【功能与主治】、【用法与用量】、【注意】、【贮藏】等固定项目。图 3.1 展示了药典原文中典型品种条目的字段结构示例。

在 MinerU 解析结果的基础上，本文进一步编写后处理脚本，利用正则表达式^[17]对各品种的字段进行精细化提取。具体方法为：以“【品名】”作为品种起始标记，依次匹配后续各字段标题，将相邻字段标题之间的文本归入前一字段，遇到下一个品种的“【品名】”时终止当前品种记录。通过此方法，全部 3069 余个品种被成功解析为以品种为基本单位、以字段为属性的结构化记录。

解析后的文本中仍然存在影响后续处理和检索质量的噪声。本文对解析后的文本实施了系统化的清洗操作，主要包括以下三个方面。

一、无关内容移除

针对解析后文本中包含的页眉、页脚、页码、分隔线等冗余排版信息，通过正则表达式实现无关内容过滤。具体包括：移除页码行（如“第 X 页”）、移除药典版本页眉（如“中国药典 XXXX 年版”）、剔除连续符号构成的章节分隔线、清除 Markdown 格式污染链接，并过滤仅含空白与符号的无效行，最终保留纯净的正文内容。

茯苓皮

Fulingpi

PORIAE CUTIS

本品为多孔菌科真菌茯苓 *Poria cocos* (Schw.) Wolf 菌核的干燥外皮，多于 7~9 月采挖，加工“茯苓片”、“茯苓块”时，收集削下的外皮，阴干。

【性状】 本品呈长条形或不规则块片，大小不一，外表面棕褐色至黑褐色，有疣状突起，内面淡棕色并常带有白色或淡红色的皮下部分，质较松软，略具弹性，气微、味淡、嚼之粘牙。

【鉴别】 (1)本品粉末棕褐色，菌丝淡棕色，细长，直径 3~8μm，密集交结成团。

(2)取本品 0.5g，照茯苓项下的(鉴别)(3)试验，显相同的结果。

【检查】 水分 不得过 15.0% (通则 0832 第二法)。

总灰分 不得过 5.5% (通则 2302)。

酸不溶性灰分 不得过 4.0% (通则 2302)。

【浸出物】 照降溶性浸出物测定法(通则 2201)项下的热浸法测定，用精乙醚作溶剂，不得少于 6.0%。

【性味与归经】 甘、淡、平。归肺、脾、肾经。

【功能与主治】 利水消肿，用于水肿，小便不利。

【用法与用量】 15~30g。

【贮藏】 置于干燥处，防潮。

图 3.1 药典茯苓皮的条目字段结构

```
def remove_irrelevant_lines(text: str) -> str:
    lines = text.splitlines()
    cleaned = []
    for line in lines:
        s = line.strip()
        # 移除页码、页眉页脚类噪声
        if re.fullmatch(r"第?\s*\d+\s*页.*", s):
            continue
        if re.search(r"中国药典\d{4}年版", s):
            continue
        if re.fullmatch(r"[-_]{3,}", s):
            continue
        # 移除行级链接污染（例如：[xxx](yyy)）
        s = re.sub(r"\[[^\]]+\]\([^\)]+\)", "", s)
        # 清除只有符号的空噪声行
        if re.fullmatch(r"[\s\W_]+", s or ""):
            cleaned.append("")
            continue
        cleaned.append(s)
    return "\n".join(cleaned)
```

图 3.2 无关内容移除代码实现

二、标点符号规范化

为解决文本中英文标点与中文标点混用、标点两侧存在多余空白、重复标点等格式混乱问题，实施统一规范化处理：将中文语境中的英文逗号、句号、分号、冒号自动替换为对应中文标点；统一括号格式；删除标点前后冗余空格；合并连续重复标点，保证文本标点格式规范统一、阅读与分词效果更优。

```
def normalize_punctuation(text: str) -> str:
    # 全角/半角括号统一
    text = text.replace("(", "(").replace(")", ")")

    # 将 CJK 两侧的英文标点替换为中文标点
    text = re.sub(r"(?<=[\u4e00-\u9fff]),(?=[\u4e00-\u9fff])", ",", text)
    text = re.sub(r"(?<=[\u4e00-\u9fff]);(?=[\u4e00-\u9fff])", ";", text)
    text = re.sub(r"(?<=[\u4e00-\u9fff]):(?=[\u4e00-\u9fff])", ":", text)
    text = re.sub(r"(?<=[\u4e00-\u9fff])\. (?=[\u4e00-\u9fff])", "。", text)

    # 去掉标点前多余空格
    text = re.sub(r"\s+([,。;:、! ? ])", r"\1", text)
    # 去掉左侧括号后多余空格
    text = re.sub(r"([【(])\s+", r"\1", text)

    # 压缩重复标点
    text = re.sub(r"([,。;:、! ? ])\1+", r"\1", text)

    return text
```

图 3.3 标点符号规范化代码实现

三、章节标题格式修复

针对药典文本解析后出现的章节标题符号缺失问题（如“性状】”），对药典标准章节名称进行精准匹配与格式校正。通过正则表达式自动补全缺失的左方括号，将不规范标题统一修复为标准格式（如“【性状】”），确保章节结构标记统一、文本格式规范化。

```
def fix_section_brackets(text: str) -> str:
    # 把 "性状】" 这类缺失左括号的标题修复为 "【性状】"
    title_group = "|".join(map[str](re.escape, SECTION_TITLES))
    pattern = re.compile(rf"(?<![\s])\b({title_group})\b")
    return pattern.sub(r"【\1】", text)
```

图 3.4 章节标题格式修复代码实现

经过上述清洗流程，药典文本的质量和一致性得到显著提升，为后续的数据分块和检索索引构建奠定了良好基础。

四、数据分块与数据结构化

数据分块是 RAG 知识库构建的关键环节，分块策略直接影响检索的粒度和召回效果。药典文本以字段为天然的知识组织单元，每个字段（如【性味与归经】、【功能与主治】）在语义上高度内聚、相对独立。因此，本文采用字段级分块策略，将每个品种的各个字段独立划分为一个检索块，确保每个块包含完整的语义信息，避免按固定字数切分割裂药典描述的完整性。

之后检索块以 JSON 格式进行结构化存储，每条记录包含 `chunk_id`（唯一标识符）和 `content`（检索块文本内容）。图 3.5 展示了一个典型的结构化检索块示例。


```

[[
  {
    "chunk_id": "chunk_000001",
    "content": "【品名】一枝黄花\n【正文】Yizhihuanghua\n\nSOLIDAGINISHERBA\n\n本品为菊科植物一枝黄花 Solidagodecurrens Lour. 的干燥全草。秋季花果期采挖，除去泥沙，晒干。"
  },
  {
    "chunk_id": "chunk_000002",
    "content": "【品名】一枝黄花\n【性状】（第 1 段）本品呈不规则的段。根茎短粗，簇生淡黄色细根。茎圆柱形，直径  $0.2\sim 0.5\mathrm{cm}$ ；表面黄绿色、灰棕色或暗紫红色，有棱线，上部被毛；质脆，易折断，断面纤维性，有髓。叶多皱缩、破碎；先端稍尖或钝，全缘或有不规则的疏齿，基部下延成柄。偶有黄色舌状花残留，多皱缩扭曲，卵状披针形，瘦果细小。气微香，味微苦辛。"
  },
  .
  .
  .
  {
    "chunk_id": "chunk_000011",
    "content": "【品名】一枝黄花\n【贮藏】置干燥处。"
  }
]]

```

图 3.5 药典结构化检索块示例（JSON 格式）

经过上述处理流程，从《中国药典》一部共生成约 33961 个结构化检索块，覆盖全部 3069 余个品种的所有知识字段。这些检索块直接构成本文 RAG 系统的知识库底层数据。

3.3 微调数据集构建

本节介绍用于大语言模型微调的数据集构建工作。微调数据由开源对话数据集和基于药典内容生成的问答对两部分组成，两者在数据类型和语言风格上形成互补，共同支撑模型在中药知识问答场景下的能力提升。

一、开源数据集

为增强模型的对话交互能力和口语化表达理解能力，从公开平台 ModelScope 收集了 HuatuoGPT-sft-data-v1、Medical_consultation_data_SFT 和 ChatMed_Conconsult_Dataset 三个开源医疗对话数据集，经主题相关性筛选、质量审核和去重后，共选取约 8000 条高质量对话样本纳入微调数据池。三个数据集分别覆盖诊疗咨询、用药指导和中医辨证等场景，语言表达自然、贴近真实用户提问习惯，与药典的规范陈述式语言形成互补。筛选遵循以下准则：保留与中药材、中药方剂、中药调理、中医辨证等直接相关的对话样本，剔除检验指标解读等不相关内容；剔除回答质量过低、存在明显事实错误或不完整的样本；确保对话结构清晰，包含明确的用户输入和助手回复字段。

二、药典数据生成问答对

药典原始文本以说明性、陈述性表述为主，缺乏“指令-回答”的对话格式，需基于药典内容生成符合指令微调格式的问答对数据。因此利用 DeepSeek-V3，以药典各品种的【功能与主治】、【用法与用量】、【注意】、【性味与归经】等字段为知识依据，设计提示模板引导模型生成覆盖功效询问、用法咨询、禁忌查询、对比提问等多种角度的问答对。生成工作围绕以下目标展开：将药典陈述性描述转换为自然的一问一答形式；确保回答内容严格忠实于药典原文，不引入额外信息或产生事实偏差。最终生成的问答对以 input-output 格式独立存储，与开源数据集合并构成完整的微调训练数据。提示词模板示例如图 3.6：

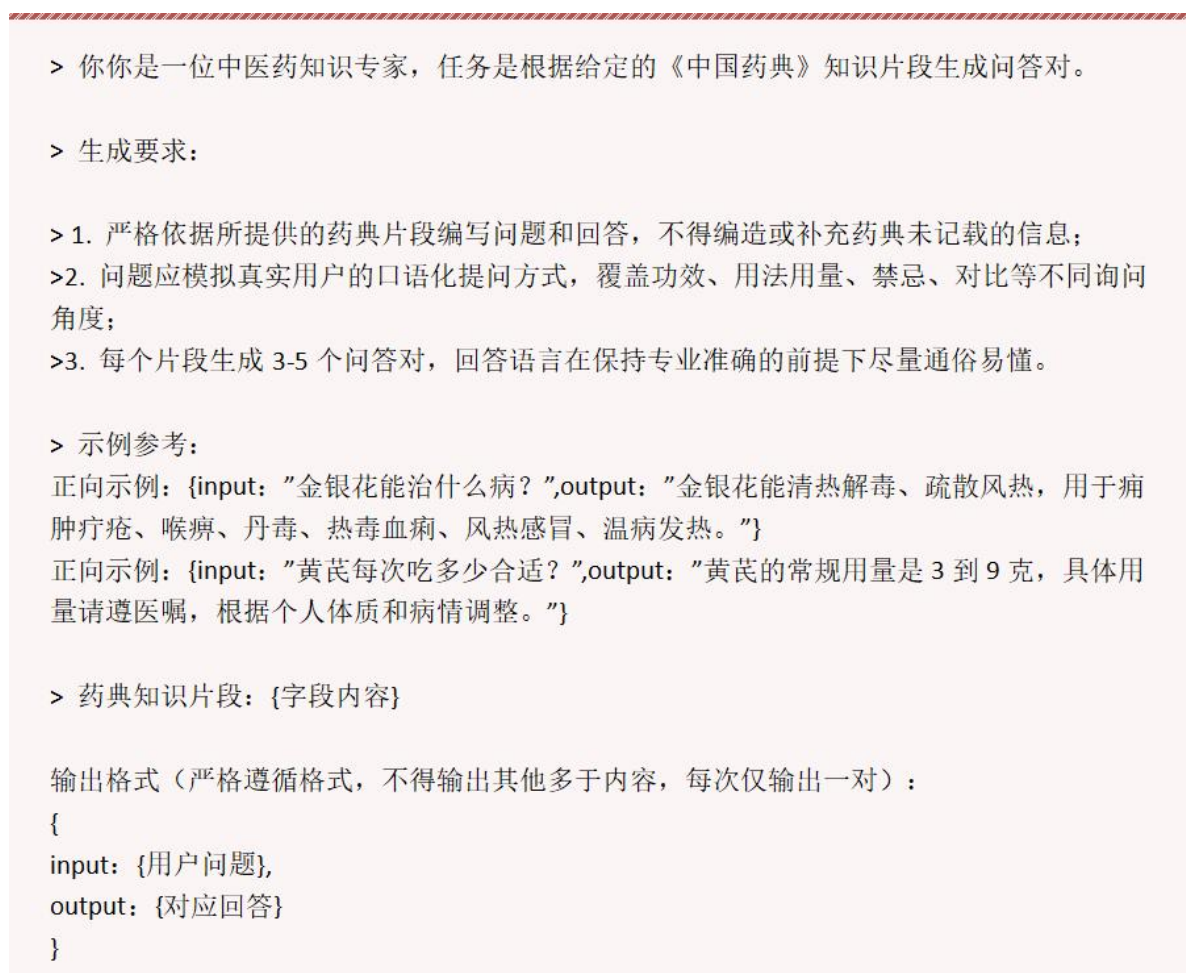


图 3.6 微调数据生成提示词模板

3.4 RAG 及大模型评测问答集设计

为系统性评估 RAG 系统在检索阶段与生成阶段的综合表现，本文构建了一套统一的评测问答集，同时服务于 RAG 检索效果评测与大模型生成质量评测。评测集的构建遵循三项原则：问题覆盖药材功效、方剂组成、用法用量、禁忌注意、药材鉴别等主要

知识类型；既包含事实性查询，也包含需综合多处信息的整合型问题，兼顾不同口语化程度的表述方式；每个问题均标注相关品种名称和问题类型，便于自动评测与分类分析。评测集独立于微调训练数据，以确保评测的客观性，数据格式如图 3.7 所示。

```
[{"query": "六味地黄丸一般怎么服用？", "query_type": "usage", "relevant_names": ["六味地黄丸"], "reference_answer": "口服。一次 8 丸，一日 3 次。", "must_include_keywords": ["六味地黄丸", "用法与用量"], "expected_fields": ["cure_way"]}, {"query": "服用甘草需要注意什么？", "query_type": "prevent", "relevant_names": ["甘草"], "reference_answer": "不宜与海藻、京大戟、甘遂、芫花同用。", "must_include_keywords": ["甘草", "预防"], "expected_fields": ["prevent"]}]
```

图 3.7 评测数据集示例（JSON 格式）

评测数据集采用 JSON 格式存储，每行一个 JSON 对象，包含 query（用户问题）、query_type（问题类型）、relevant_names（相关药材或方剂名称列表）、reference_answer（标准答案）、must_include_keywords（必须命中的关键实体与领域术语）、expected_fields（与问题类型对应的字段标签）六个字段。数据生成过程中，利用大语言模型依据不同品种的药典内容，设计提示模板批量生成覆盖各类问题类型的评测样本，并经人工复核确保答案准确、字段标注无误。

第四章 医疗大语言模型微调实验

本章在构建好的数据集基础上，对四种基座大语言模型进行面向中医药知识问答领域的微调实验。首先介绍所选基座模型的基本情况与选取依据，然后详细说明微调实验的训练策略、超参数配置及训练过程监控方法，最后在医疗知识评测集上对比基座模型与微调模型在多个指标上的性能表现，并对四种模型的微调效果进行分析与讨论。

4.1 基座模型选择

为系统性评估不同大语言模型在中医药知识问答领域的微调潜力，本文选取了四种具有代表性的开源基座模型进行对比实验。选取时综合考虑了模型的中文能力、参数规模、指令遵循能力和社区生态等维度。四种基座模型的基本信息如表 4.1 所示。

表 4.1 四种基座模型概况

模型名称	参数规模	主要特点
Qwen2.5-7B-Instruct	7B	中文综合能力优秀，支持长上下文，适配 ChatML 格式
Qwen3-8B	8B	通义千问最新一代模型，在 Qwen2.5 基础上改进训练策略，推理能力进一步增强
Llama3-8B-Instruct	8B	Meta 开源系列指令微调版本，社区生态完善，中文能力较早期版本显著提升，适配 Alpaca 格式
Baichuan2-7B-Chat	7B	百川智能专为中文场景优化的对话模型，训练数据包含大量中文互联网与知识语料

四者均为 Dense Transformer 结构，参数规模集中在 7B-8B 区间。在架构相同的前提下可更清晰地观察不同预训练策略与中文语料占比对微调效果的影响；Qwen2.5-7B^[18]、Qwen3-8B^[19]中文能力突出，Llama3-8B^[20]多语言均衡且社区生态完善，Baichuan2-7B^[21]针对中文对话场景有专门优化，四者形成互补，有助于从多个角度评估 LoRA 微调在中药知识问答任务上的增益效果。

4.2 微调实验设置

本文的微调实验依托 LLaMA-Factory 框架^[22]进行，该框架内置 PT、SFT、LoRA、QLoRA 等多种微调方法，提供从数据加载到训练调度的一体化 workflow，适合多模型对比实验。

一、训练策略与超参

本文采用 LoRA 对四种基座模型进行参数高效微调^[6]。LoRA 模块注入各模型注意力层的查询投影（q_proj）、键投影（k_proj）、值投影（v_proj）和输出投影（o_proj）四个线性层，训练时冻结基座模型全部预训练权重，仅优化低秩矩阵，推理阶段将 LoRA 权重与原始权重合并，不引入额外推理延迟。选择 LoRA 主要基于以下考量：四种模型的微调均在单张 NVIDIA RTX 4090（24GB 显存）上完成，LoRA 的低显存占用特性使 7B-8B 级别模型的并行实验成为可能；统一的微调方法确保模型间对比的公平性，微调增益的差异仅反映模型自身对领域数据的适应能力。

四种模型采用统一的超参数配置进行微调，具体配置如表 4.2 所示。

表 4.2 微调超参数配置

超参数	配置值	说明
LoRA 秩（r）	8	控制可训练参数量，在表达能力和防止过拟合之间取平衡
学习率	1e-4	初始学习率，取值偏保守以平稳注入领域知识
学习率调度	Cosine	余弦退火策略，随训练步数逐步衰减
批次大小	2	每 GPU 每步训练样本数
梯度累积步数	4	等效批次大小为 8
训练轮次（Epochs）	3	完整遍历训练集 3 次
最大序列长度	1024 tokens	单条样本的最大截断长度
精度	BF16	与 FP32 相同动态范围，减少显存占用且保证训练稳定
最大训练样本数	15000	训练集参与训练的最大样本数量

超参数设置如下：LoRA 秩取 8，在 7-8B 模型上能在控制可训练参数量与表达能力之间取得平衡；学习率取 1e-4 偏保守值，旨在平稳注入领域知识的同时最大限度保留基座模型的通用语言能力；采用 BF16 精度训练，与 FP16 相比指数位与 FP32 一致，可有效避免梯度下溢和溢出问题；受限于单张 GPU 显存，每 GPU 批次大小设为 2，通过 4 步梯度累积使等效批次达到 8，以较小显存代价模拟更大批次的稳定梯度估计。

二、训练过程监控

为跟踪微调过程的收敛状态，本文对四种模型训练过程中的训练损失和验证损失变化进行了同步记录。图 4.1 至图 4.4 分别展示了 Qwen2.5-7B、Qwen3-8B、Llama-3-8B-Instruct 和 Baichuan2-7B-Chat 在微调过程中的训练损失曲线与验证损失曲线。




图 4.1 Qwen2.5-7B 训练损失与验证损失曲线




图 4.2 Qwen3-8B 训练损失与验证损失曲线




图 4.3 Llama3-8B-Instruct 训练损失与验证损失曲线




图 4.4 Baichuan2-7B-Chat 训练损失与验证损失曲线

从四张损失曲线图可以看出，四种模型在微调过程中均呈现出训练损失与验证损失同步下降、整体趋势一致的特征，且两者数值差距极小，未出现验证损失上升而训练损失下降的发散现象。具体而言，Llama3-8B-Instruct 的初始损失相对较高，但下降速度较快，约在 1000 步后趋于平缓；Qwen2.5-7B 和 Qwen3-8B 的损失曲线波动较小，收敛过程平稳；Baichuan2-7B-Chat 在训练中后期出现小幅波动，但整体仍保持同步下降趋势至训练结束。

四种模型的损失曲线均未出现发散、剧烈振荡或过拟合的异常情况，且训练末期均趋于平缓，表明学习率设置合理，训练过程稳定，LoRA 微调在四种基座模型上均能有效收敛。训练损失与验证损失的高度一致性，进一步证明模型能够将训练中学到的知识有效泛化到验证数据中。

4.3 微调效果评测

为客观评估微调前后模型在医学知识问答上的能力变化，采用开源评测框架 OpenCompass，在三个标准医学问答数据集上进行自动化评测，对比基座模型与微调模型的性能差异。

一、评测平台与数据集

本文选用 OpenCompass 作为评测平台^[23]。该平台由上海人工智能实验室打造，集成了多个权威医学评测数据集，支持一站式标准化评测。本文选用 MedQA_US（美国执业医师资格考试）、MedQA_Mainland（中国大陆执业医师资格考试）和 MedQA_Taiwan（中国台湾地区执业医师资格考试）三个医学问答数据集^[24]作为评测基准，以准确率

（Accuracy）作为评测指标，即模型正确回答的问题数占总问题数的百分比，计算公式为(4-1)。

$$Accuracy = \frac{N_{correct}}{N_{total}} \times 100\% \quad (4-1)$$

其中， $N_{correct}$ 为模型正确回答的问题数量， N_{total} 为评测数据集的总问题数量。

二、四种模型微调前后性能对比

使用 OpenCompass 对四种基座模型及其微调版本在 MedQA_US、MedQA_Mainland、MedQA_Taiwan 三个数据集上分别进行评测，基座模型与微调模型的准确率对比如下。

(1) 基座模型评测结果

四种基座模型在三个医学数据集上的准确率如表 4.3 所示。

表 4.3 基座模型医学评测准确率（%）

模型	MedQA_US	MedQA_Mainland	MedQA_Taiwan
Qwen2.5-7B-Instruct	45.45	51.48	52.80
Qwen3-8B	48.67	56.42	58.10
Llama3-8B-Instruct	41.35	50.17	53.78
Baichuan2-7B-Chat	34.47	49.68	52.82

(2) 微调模型评测结果

四种基座模型经 LoRA 微调后，在相同三个医学数据集上的准确率如表 4.4 所示。

表 4.4 微调模型医学评测准确率（%）

模型	MedQA_US	MedQA_Mainland	MedQA_Taiwan
Qwen2.5-7B-Instruct-Lora	51.53	62.70	65.96
Qwen3-8B-Lora	57.27	68.56	69.18
Llama3-8B-Instruct-Lora	48.56	57.47	60.87
Baichuan2-7B-Chat-Lora	41.65	54.27	57.61

三、模型效果分析




图 4.5 基座模型与 LoRA 微调模型医学评测准确率对比

如图 4.5 所示，LoRA 微调对四种模型的医学问答能力均有提升，但不同模型的提升幅度与最终表现存在分化。Qwen3-8B 微调后在三个数据集上均取得最高准确率，且相较基座模型的提升幅度最大，表明其在中医药领域数据上的适应能力最强。Qwen2.5-7B-Instruct 微调后表现紧随其后，在准确率与推理效率之间取得了较好的平衡。Llama3-8B-Instruct 和 Baichuan2-7B-Chat 微调后准确率也有明显提升，但整体水平低于 Qwen 系列。总体来看，Qwen 系列模型在中文医学知识问答任务上具有更优的基础能力和更大的微调增益空间。

第五章 基于 LangGraph 与 RAG 的医疗智能体设计与实验

本章在知识库构建和模型微调的基础上，详细阐述基于 LangGraph 与 RAG 的医疗智能体设计与实验。首先介绍智能体的总体架构设计与工作流程，然后依次阐述查询理解与意图分流机制、多策略检索设计与检索性能对比实验、基座模型与微调模型的接入与流式输出，最后通过幻觉现象检测实验，系统评估不同模型在忠实度、实体命中率和字段级事实准确性等方面的表现，为智能体的生成模型选择提供实验依据。

5.1 智能体总体架构设计

本文设计的医疗智能体以 LangGraph 为流程编排引擎^[12]，以《中国药典》知识库为外部知识源，以微调后的大语言模型为生成核心，实现了从用户输入到流式输出的完整问答链路。系统整体工作流如图 5.1 所示，由缓存查找、意图路由、查询改写、多策略检索、检索重试、答案生成、缓存保存和流式输出八个核心节点通过条件边连接构成有向状态图。




图 5.1 医疗智能体整体工作流（LangGraph 状态图）

系统运行流程如下：用户输入首先进入缓存查找节点，若命中缓存则直接返回历史回答；未命中时进入意图路由节点，由轻量大模型将输入判定为敏感拒答、闲聊或医疗问诊三类。医疗类查询经查询改写节点转换为规范化检索式后，进入多策略检索节点，融合 BM25 关键词检索与 BGE-M3 稠密向量检索的结果；若检索为空则自动重试。最终由微调后的生成模型基于检索文档生成回答，写入缓存后以流式方式返回前端。

5.2 查询理解与意图分流

查询理解与意图分流包含缓存查找、意图路由和查询改写三个环节：缓存命中则直接返回；未命中时由意图路由判定为敏感拒答、闲聊或医疗问诊；仅医疗问答时进一步进行查询改写，将口语化表达转换为规范检索语句。本节将分别阐述缓存查找机制、意图路由设计及查询改写策略。

一、缓存查找机制

系统在入口处首先进行缓存查找。基于 Redis 的 String 数据结构，以用户原始查询文本为键查询缓存。若命中，则直接返回历史回答，跳过后续全部处理流程；若未命中，则依次进入意图路由和查询改写环节。缓存策略采用字符串精准匹配而非语义相似度匹配，原因在于医学问答对药品名、剂量等实体高度敏感，语义相近但实体不同的回答可能引发用药风险。

```
# 查询
def get_answer(self, question):
    if not self.enabled:
        return None
    try:
        val = self.redis_node.get(f"qa:{question}")
        print("连接成功 redis数据库")
        return val
    except Exception as e:
        self.enabled = False
        print(f"Redis查询失败, 已降级为无缓存模式: {e}")
        return None

# 保存
def save_qa(self, question, answer):
    if not self.enabled:
        return
    try:
        self.redis_node.setex(f"qa:{question}", 360, answer)
        print("保存成功 redis数据库")
    except Exception as e:
        self.enabled = False
        print(f"Redis写入失败, 已降级为无缓存模式: {e}")
```

图 5.2 缓存查找机制示意图

二、意图路由设计

意图路由节点负责将用户输入判定为三类：敏感拒答、闲聊或医疗问诊。其中，敏感拒答分支拦截涉及高危敏感话题的不当输入，返回固定拒答语，从源头保障安全合规；闲聊分支将问候、日常寒暄等非医疗对话直接引导至闲聊节点，避免触发后续检索流程；只有医疗分支进入完整的查询改写与检索链路。该设计将安全拦截、意图分流统一于单次轻量级大模型调用中完成，通过设计提示词模板引导模型进行三分类判定，分类逻辑如图 5.3 所示。




图 5.3 意图路由分类逻辑示意图

当判定结果为 **refuse** 时，系统返回固定拒答语：“抱歉，该问题涉及敏感内容，无法回答。建议您寻求专业人士帮助。”当判定结果为 **chitchat** 时，跳转至闲聊节点直接对话回应；当判定结果为 **medical** 时，进入查询改写和检索流程。该设计将安全合规、意图分流统一于单次 LLM 调用中完成，结构简洁且判定灵活。

三、查询改写策略

查询改写节点承接医疗意图，将用户的口语化、简略或模糊表达转换为更适合检索的规范化查询文本。典型操作包括：将俗称转换为术语（如“肚子疼”转换为“腹痛”）、补全简略问法（如“怎么吃”转换为“用法用量”）、生成同义改写变体以扩大召回覆盖面。改写同样使用轻量级大模型完成，提示词指示模型输出适合检索的规范查询语句，用词贴近药典术语体系。提示词模板如图 5.4 所示。

```
prompt = (  
    "你是医疗检索问句改写专家，请对用户原始医疗问题做标准化精简改写，用于知识库检索。\\n"  
    "严格遵循以下规则：\\n"  
    "1. 精简为单行简短中文检索问句，不拆分、不换行、不输出多余内容；\\n"  
    "2. 必须完整保留核心实体：疾病名称、身体部位、症状、药品、检查项目、诊疗方式、病因、禁忌人群；\\n"  
    "3. 删除口语助词、冗余修饰、情绪感叹、无关客套话、重复表述；\\n"  
    "4. 统一口语表述为专业通俗说法，不新增原意没有的信息、不扩写、不编造；\\n"  
    "5. 只输出改写后的检索短句，不要解释、不要分析、不要额外说明。\\n\\n"  
    f"原始医疗问题：{query}\\n"  
    "标准化检索改写："  
    )
```

图 5.4 查询改写提示词模板

5.3 多策略检索设计与实验

中医药知识库中的查询语言通常呈现口语化、术语简略或俗称混用的特点，单一检索方式难以同时兼顾精确匹配与语义泛化需求。BM25 关键词检索对药材名、方剂名等专有术语匹配精准，但无法处理同义表达；稠密向量检索具备语义理解能力，却可能在关键术语上出现排序偏差。为充分发挥两类检索方法的互补优势，本节设计了一种多策略检索方案，通过融合 BM25 稀疏检索与 BGE-M3 稠密向量检索的结果，并采用倒数排序融合^[11]（RRF）策略对召回文档进行重排序。以下分别介绍混合检索与融合策略的具体实现，以及不同检索模式在评测集上的性能对比实验。

一、混合检索与融合策略

单一检索方式各有侧重。本文采用倒数排序融合（RRF）对两路检索结果进行融合，相关原理如第 2.2 节所述。在具体实现中，BM25 检索和 Embedding 检索各自返回 Top-5 结果，RRF 对两路结果的排名进行融合后重新排序，取前 K 条作为最终检索结果。设置平滑常数 $k=60$ ，对于仅在单路检索中出现的文档，缺失路的排名按 Top-K+1 处理。此外，系统设计了检索重试机制：当融合后的检索结果为空且重试次数未达上限时，自动调整检索参数重新检索，以增强系统的鲁棒性。

二、检索性能对比实验

为评估不同检索策略在中药知识库上的表现，本文在第 3.4 节构建的评测集上进行了召回实验，对比了 BM25、Embedding 和 RRF 三种模式的检索效果，结果如表 5.1 所示。

表 5.1 检索策略评测集召回模式对比

Method	Hit@3	Recall@3	MRR@3	nDCG@3	Hit@10	Recall@10	MRR@10	nDCG@10
BM25	76.50	71.17	67.58	66.36	86.17	79.39	69.45	69.63
Embedding	97.67	90.56	92.00	88.39	98.00	91.89	93.08	90.55
RRF (k=60)	99.33	91.67	98.53	92.67	99.83	91.86	94.83	92.24

由表 5.1 可知，RRF 在所有指标上均优于单一检索方法，其 Hit@3 达到 99.33%，MRR@3 达到 98.53%，表明混合检索能够将最相关文档稳定置于首位。Embedding 检索全面领先 BM25，Hit@3 高出 21.17 个百分点，证实语义向量检索在弥合口语化查询与药典术语差异上的关键作用。RRF 相比 Embedding 的增益主要集中在排序指标：MRR@3 从 92.00 升至 98.53，提升 6.53 个百分点；nDCG@3 从 88.39 升至 92.67，提升 4.28 个百分点。这说明 RRF 的主要价值并非增加召回数量，而是利用 BM25 的精确匹配修正 Embedding 的排序位置。综合来看，RRF 兼顾了语义泛化与精确匹配，因此本文在后续智能体评测中采用 RRF 策略。

5.4 模型接入与流式生成

本节主要完成基座模型与 LoRA 微调模型的推理接入，并基于 vLLM 框架实现模型部署与流式生成，使智能体能够高效、稳定地向用户返回连续、流畅的回答内容，保障系统交互体验。

一、基于 vLLM 的模型接入与部署

vLLM^[25]是面向大语言模型的高性能开源推理部署框架，核心采用 PagedAttention 分页注意力机制，可高效利用显存、降低内存碎片，大幅提升模型推理吞吐量与并发能力。该框架支持主流开源大模型快速部署，提供与 OpenAI 完全兼容的 API 接口，能够无缝对接 LangGraph 智能体编排系统，同时原生支持流式输出，完美适配中医药实时问答场景。

本文采用 vLLM 推理框架对基座模型与微调后模型进行统一部署，vLLM 模型部署如图 5.5 所示。通过命令行指定模型路径、绑定服务地址与端口并配置远程代码信任，完成模型服务启动。部署完成后，模型以 OpenAI 兼容的标准化 API 接口对外提供推理服务，LangGraph 智能体在生成节点通过 API 调用模型，即可完成答案生成。vLLM 可兼容多种主流开源大语言模型，支持高效推理与流式输出，能够显著提升系统的响应速度、并发能力与运行稳定性。



二、流式生成实现

5.5 幻觉现象检测与实验结果分析

本节利用第 3.4 节构建的评测问答集，将四种基座模型及其 LoRA 微调版本模型分别接入智能体的生成节点进行对比实验。对每个模型生成的回答，我们计算 BERTScore、ROUGE-L、EntHit、Faith、Field 以及 Latency 六项指标。其中，Faith、EntHit 和 Field 是专门针对幻觉设计的评估维度，能够从整体忠实度、关键实体和药典字段细节三个层次衡量回答的事实可靠性。评测结果如表 5.2 所示。

模型	BERTScore	ROUGE-L	EntHit	Faith	Field	Latency (ms)
Qwen2.5-7B-Instruct	0.7080	0.3317	0.9258	0.5463	0.3770	2008.7
Qwen2.5-7B-Instruct-LoRA	0.7324	0.3614	0.9484	0.5687	0.4053	2234.3
Qwen3-8B	0.7309	0.3937	0.9378	0.5577	0.4507	7611.2
Qwen3-8B-LoRA	0.7424	0.4087	0.9457	0.5860	0.4786	7451.6
Baichuan2-7B-Chat	0.6798	0.2710	0.9258	0.5037	0.3776	2563.2
Baichuan2-7B-Chat-Lora	0.6987	0.2846	0.9386	0.5274	0.3856	2633.5

表 5.2 (续)

模型	BERTScore	ROUGE-L	EntHit	Faith	Field	Latency (ms)
Llama3-8B-Instruct	0.6675	0.2657	0.9186	0.6569	0.3831	3109.5
Llama3-8B-Instruct-LoRA	0.6749	0.2957	0.9142	0.6386	0.3562	3029.3




图 5.6 LangGraph+RAG 框架下基座模型与微调模型幻觉检测指标对比

由表 5.2 和图 5.6 可知, LoRA 微调后四个模型在 BERTScore、ROUGE-L、EntHit、Faith 和 Field 指标上均有不同程度提升, 其中 Field 指标增幅最为明显, 验证了微调对中医药字段级知识准确性的正向作用。在回答质量方面, Qwen3-8B-LoRA 在 BERTScore (0.7424)、ROUGE-L (0.4087)、Faith (0.5860) 和 Field (0.4786) 四项指标上均排名第一, 综合表现最优, 但其推理延迟高达 7451.6ms, 约为其他模型的 3 倍, 实时性存在明显短板。Qwen2.5-7B-Instruct-LoRA 各项指标均排名第二, 其中 EntHit 最高(0.9484), 且延迟仅 2234.3ms, 在准确性与响应速度之间取得了最佳平衡。在幻觉抑制方面, Llama3-8B-Instruct 的 Faith 得分在微调前后均保持领先 (0.6569/0.6386), 忠实度最强, 但 Field 得分偏低, 说明其在遵循药典结构化字段方面仍有不足。Baichuan2-7B-Chat-LoRA 整体表现相对靠后, Field (0.3856) 和 Faith (0.5274) 均低于 Qwen 系列, 提升幅度有限。延迟方面, 微调前后差异较小, 符合 LoRA 权重合并后不引入额外推理开销的理论预期。

综合来看, Qwen2.5-7B-Instruct-LoRA 在回答质量、幻觉抑制与响应效率之间取得了最佳平衡, 推荐作为系统默认生成模型; 若追求极致的准确性且可容忍较高延迟, Qwen3-8B-LoRA 表现最优; 若将忠实度 (最低幻觉风险) 作为首要安全考量, Llama3-

8B-Instruct-LoRA 最为合适。Baichuan2-7B-Chat-LoRA 在各指标上均不占优势，不予推荐。上述结论为智能体的模型选型提供了量化依据，同时也验证了在 LangGraph 编排的 RAG（采用 RRF）框架下，LoRA 微调能够有效降低医疗问答幻觉、提升回答可靠性。

第六章 中药知识问答原型系统界面设计与实现

为将前述智能体系统转化为用户可直接交互的问答应用，本文基于 Gradio 框架构建了 Web 交互式界面。本章首先介绍 Gradio 框架的基本特点与选型理由，然后展示系统界面的整体布局与核心交互功能，并结合典型问答案例说明系统的实际使用效果。

6.1 Gradio 框架简介

Gradio 是一款由 Hugging Face 团队开发的开源 Python 库，专为机器学习模型的快速演示与交互式应用而设计^[26]。其核心优势在于接口自动生成——开发者只需定义输入输出组件类型即可生成 Web 界面，无需前端开发；同时内置流式输出支持与对话历史管理功能，适配大语言模型问答场景。本文选用 Gradio 作为前端框架，主要基于以下考量：文本框组件与流式生成器接口可覆盖问答系统的全部交互需求，且与 LangGraph 编排的智能体后端通过 Python 接口无缝对接，无需额外的服务封装。

6.2 系统界面设计与功能展示

本文基于 Gradio 构建的医疗智能体问答系统界面如图 6.1 所示。界面采用对话式布局：顶部为系统标题区，中部以聊天气泡形式呈现用户提问与系统回答的历史记录，底部由文本输入框、发送按钮和示例面板组成。示例面板提供常见查询标签，点击即可自动填入并发起查询。用户输入问题后，经 Gradio 接口传入 LangGraph 编排的智能体后端，依次完成意图路由、查询改写、多策略检索与生成，最终以流式方式返回回答并在对话区逐段展示。



图 6.1 医疗智能体问答系统 Web 界面（Gradio）

通过 Gradio 界面的搭建，前置章节所设计的检索增强生成与 LangGraph 智能体编排技术转化为用户可直接交互的问答工具，完成了从理论方法到系统实现的完整闭环。

第七章 总结与展望

7.1 总结

本文围绕“基于 LangGraph 与 RAG 的医疗智能体构建与实现”这一课题，以中医药知识问答为应用场景，针对通用大语言模型在专业医疗问答中存在的知识依据不清、知识更新滞后、专业术语理解不足和幻觉生成等问题，开展了数据构建、模型微调、检索增强、智能体编排和原型系统实现等方面的研究。通过对全文工作的设计与验证，本文形成了一套面向中医药知识服务的医疗智能体实现方案。

本文以《中国药典》2025 年版一部为核心知识来源，利用文档解析工具对药典文本进行结构化提取，并通过无关内容移除、标点规范化、字段标题修复等步骤完成数据清洗。在此基础上，依据药典条目的字段结构进行字段级分块和 JSON 结构化存储，构建了适用于 RAG 检索的中医药知识库。该知识库保留了药典中药材、饮片、成方制剂等内容的规范字段结构，为后续检索增强生成提供了权威、稳定的知识来源。本文结合开源医疗问答数据和基于药典内容生成的问答对，构建了用于领域适配的指令微调数据集，并选择多种开源大语言模型作为基座模型，采用 LoRA 参数高效微调方法进行训练与对比评测。实验结果表明，LoRA 微调能够在不显著增加推理开销的情况下提升模型对中医药问答任务的适应能力，使模型在回答质量、实体命中、字段级事实准确性和知识表达规范性方面得到改善。不同模型在准确性、忠实度和响应速度方面存在差异，其中 Qwen3 类模型在综合准确性方面表现较好，Qwen2.5 类模型在响应效率和整体效果之间更为均衡，说明实际部署时需要结合应用需求进行模型选择。

设计了融合 BM25 稀疏检索、BGE-M3 稠密检索和 RRF 排序融合的多策略检索方案。BM25 能够较好处理药材名、方剂名等专业术语的精确匹配问题，稠密向量检索能够补充自然语言语义匹配能力，RRF 融合则能够降低单一检索方式带来的偏差。通过将检索结果作为模型生成回答的上下文，RAG 机制能够为回答提供外部知识依据，增强答案的可追溯性，并在一定程度上降低模型凭借参数记忆生成错误内容的风险。在系统实现层面，本文基于 LangGraph 将缓存查找、意图路由、查询改写、多策略检索、上下文组装、答案生成和流式输出等环节组织为统一的状态图工作流，并基于 Gradio 实现中药

知识问答原型系统。与简单串行调用方式相比，LangGraph 的状态图编排使系统流程更加清晰，便于后续扩展安全审核、检索重试、多轮对话管理和日志追踪等功能。原型系统能够支持用户以自然语言提问，并返回较为规范的中医药知识回答，基本实现了本文设定的研究目标。

7.2 不足与展望

尽管本文完成了医疗智能体的基本构建与实验验证，但仍存在一些不足。第一，知识库主要来源于《中国药典》一部，虽然权威性较强，但知识范围仍偏向标准条目，对临床诊疗经验、辨证论治过程和多源医学指南的覆盖不足。第二，微调数据和评测问答集规模有限，部分问答对由模型辅助生成，仍需要进一步引入专家审核和更大规模的真实用户问题进行验证。第三，系统目前主要面向中医药知识查询，不应直接用于疾病诊断、处方推荐或个体化治疗决策，医疗安全边界和合规提示仍需加强。第四，原型系统仍以实验验证为主，在并发访问、长期运行稳定性、模型推理成本和工程化部署方面仍有改进空间。

后续研究可从以下几个方向继续完善。首先，可进一步扩展知识来源，将药典知识与中医药教材、临床指南、标准文献和专家审定资料结合起来，构建覆盖更广、层次更清晰的中医药知识库。其次，可引入更精细的安全控制机制，例如医疗风险问题识别、禁忌内容校验、回答依据展示、拒答策略和免责声明提示，以降低系统在实际应用中的误导风险。再次，可优化检索链路，引入重排序模型、查询分解、多轮检索和知识图谱辅助推理，提高复杂问题下的召回质量和答案一致性。最后，可在工程层面优化模型部署与系统服务能力，例如采用量化推理、缓存优化、异步任务处理和日志监控等方法，提高系统响应速度、稳定性和可维护性。通过上述改进，基于 LangGraph 与 RAG 的医疗智能体有望在中医药知识服务、医学学习辅助和垂直领域智能问答系统中发挥更大应用价值。

参考文献

- [1] Brown T B, Mann B, Ryder N, et al. Language Models are Few-Shot Learners[A]. In: Neural Information Processing Systems Foundation, ed. Advances in Neural Information Processing Systems 33[C]. Virtual: Curran Associates, 2020: 1877-1901.
- [2] Singhal K, Azizi S, Tu T, et al. Large language models encode clinical knowledge[J]. Nature, 2023, 620(7972): 172-180.
- [3] Ji Z, Lee N, Frieske R, et al. Survey of Hallucination in Natural Language Generation[J]. ACM Computing Surveys, 2023, 55(12): 1-38.
- [4] 国家药典委员会. 中华人民共和国药典：2025 年版一部[M]. 北京：中国医药科技出版社, 2025: 1-1945.
- [5] Lewis P, Perez E, Piktus A, et al. Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks[A]. In: Neural Information Processing Systems Foundation, ed. Advances in Neural Information Processing Systems 33[C]. Virtual: Curran Associates, 2020: 9459-9474.
- [6] Hu E J, Shen Y, Wallis P, et al. LoRA: Low-Rank Adaptation of Large Language Models[A]. In: Anonymous, ed. International Conference on Learning Representations[C]. Virtual: OpenReview.net, 2022: 1-15.
- [7] Vaswani A, Shazeer N, Parmar N, et al. Attention Is All You Need[A]. In: Neural Information Processing Systems Foundation, ed. Advances in Neural Information Processing Systems 30[C]. Long Beach: Curran Associates, 2017: 5998-6008.
- [8] Robertson S, Zaragoza H. The Probabilistic Relevance Framework: BM25 and Beyond[J]. Foundations and Trends in Information Retrieval, 2009, 3(4): 333-389.
- [9] Manning C D, Raghavan P, Schütze H. Introduction to Information Retrieval[M]. Cambridge: Cambridge University Press, 2008: 1-23.
- [10] Chen J, Xiao S, Zhang P, et al. M3-Embedding: Multi-Linguality, Multi-Functionality, Multi-Granularity Text Embeddings Through Self-Knowledge Distillation[A]. In: Ku L W, Martins A, Srikumar V, eds. Findings of the Association for Computational Linguistics: ACL 2024[C]. Bangkok: Association for Computational Linguistics, 2024: 2318-2335.

- [11] Cormack G V, Clarke C L A, Buettcher S. Reciprocal Rank Fusion Outperforms Condorcet and Individual Rank Learning Methods[A]. In: Cheung D, Song I Y, et al., eds. Proceedings of the 32nd International ACM SIGIR Conference on Research and Development in Information Retrieval[C]. New York: ACM, 2009: 758-759.
- [12] LangChain. LangGraph overview [EB/OL]. <https://python.langchain.com/docs/langgraph>, 2026-04-14.
- [13] Lin C Y. ROUGE: A Package for Automatic Evaluation of Summaries[A]. In: Association for Computational Linguistics, ed. Text Summarization Branches Out[C]. Barcelona: Association for Computational Linguistics, 2004: 74-81.
- [14] Zhang T, Kishore V, Wu F, et al. BERTScore: Evaluating Text Generation with BERT[A]. In: Anonymous, ed. International Conference on Learning Representations[C]. Virtual: OpenReview.net, 2020: 1-15.
- [15] Es S, James J, Espinosa-Anke L, et al. RAGAs: Automated Evaluation of Retrieval Augmented Generation[A]. In: Association for Computational Linguistics, ed. Proceedings of the 18th Conference of the European Chapter of the Association for Computational Linguistics: System Demonstrations[C]. St. Julians: Association for Computational Linguistics, 2024: 150-158.
- [16] Wang B, Xu C, Zhao X, et al. MinerU: An Open-Source Solution for Precise Document Content Extraction[EB/OL]. (2024-09-28)[2026-04-14]. <https://arxiv.org/abs/2409.18839>.
- [17] Friedl J E F. Mastering Regular Expressions[M]. 3rd ed. Sebastopol: O'Reilly Media, 2006: 1-20.
- [18] Yang A, Yang B, Zhang B, et al. Qwen2.5 Technical Report[EB/OL]. (2024-12-18)[2026-04-14]. <https://arxiv.org/abs/2412.15115>.
- [19] Yang A, Yang B, Zhang B, et al. Qwen3 Technical Report[EB/OL]. (2025-05-12)[2026-04-14]. <https://arxiv.org/abs/2505.09388>.
- [20] Grattafiori A, Dubey A, Jauhri A, et al. The Llama 3 Herd of Models[EB/OL]. (2024-07-23)[2026-04-14]. <https://arxiv.org/abs/2407.21783>.
- [21] Yang A, Xiao B, Wang B, et al. Baichuan 2: Open Large-scale Language Models[EB/OL]. (2023-09-18)[2026-04-14]. <https://arxiv.org/abs/2309.10305>.
- [22] Zheng Y, Zhang R, Zhang J, et al. LlamaFactory: Unified Efficient Fine-Tuning of 100+ Language Models[A]. In: Association for Computational Linguistics, ed. Proceedings of the 62nd Annual Meeting

of the Association for Computational Linguistics: System Demonstrations[C]. Bangkok: Association for Computational Linguistics, 2024: 400-410.

- [23] OpenCompass Contributors. OpenCompass: A Universal Evaluation Platform for Foundation Models[EB/OL]. (2023-07-28)[2026-04-14]. <https://github.com/open-compass/opencompass>.
- [24] Jin D, Pan E, Oufattole N, et al. What Disease Does This Patient Have? A Large-Scale Open Domain Question Answering Dataset from Medical Exams[J]. Applied Sciences, 2021, 11(14): 6421.
- [25] Kwon W, Li Z, Zhuang S, et al. Efficient Memory Management for Large Language Model Serving with PagedAttention[A]. In: Anonymous, ed. Proceedings of the 29th Symposium on Operating Systems Principles[C]. New York: ACM, 2023: 611-626.
- [26] Abid A, Abdalla A, Abid A, et al. Gradio: Hassle-Free Sharing and Testing of ML Models in the Wild[EB/OL]. (2019-06-06)[2026-04-14]. <https://arxiv.org/abs/1906.02569>.

致 谢

眨眼间，四年的本科学习生涯即将结束。是不舍，是留恋，是骄傲，亦或是遗憾，抑或兼而有之？这些都已不再重要。四年所有的经历，都将成为我人生中最珍贵的记忆，它们见证着我的成长。

经过四年的学习，我的专业技能和知识水平得到了极大的提升。这当中除了我个人的努力，更离不开师友亲朋一路的相伴与无私的帮助——在我迷茫时给予我希望，在我困惑时为我指引方向，在我懈怠时给我鞭策。没有他们的陪伴，我无法顺利完成本科阶段的学业。值此论文提交之际，谨对他们的帮助和关心表示由衷的感谢。

感谢我敬爱的常霞老师。从论文写作之初到最终定稿，您不厌其烦地为我逐字逐句把关，让我既感欣喜，又觉惭愧。欣喜的是，能够遇到这样一位严师，是我的幸运；惭愧的是，学生资质平平，让您如此费心。您一丝不苟的治学态度和对学生无微不至的关怀，我将永远铭记于心！

感谢我的家人，你们在物质上的支持是我完成学业的重要保障，你们精神上的鼓励更是我不断前行的动力。

感谢我的同学和朋友，你们在生活中给予我帮助，在学习上给予我关怀，让我从未感到孤单。

还有许多值得我铭记和感恩的人，你们一个鼓励的眼神、一个赞赏的手势、一个友好的微笑，都让我倍感温暖。衷心谢谢你们！

岁月流转，不变的是我们师生间的情谊；日月更迭，不改的是我们朋友间的意气；春去秋来，永恒的是我们家人间的亲情。

附录

本附录给出了基于 LangGraph 与 RAG 的医疗智能体系统的源代码结构与核心模块说明，系统代码仓库为：

<https://github.com/WSL666/LangGraph-RAG-Medical-Agent-WangShilin>

附录 A.1 项目整体目录结构

系统的完整目录结构如图 A.1 所示，项目采用模块化设计，分为前端交互、智能体编排、知识库检索、缓存管理四大核心模块，各模块职责清晰，便于维护与扩展。

LangGraph-RAG-Medical-Agent-WangShilinPublic

Pin

Watch0

master1 Branch0 Tags

Go to fileT

Add file

Code

WSL666 上传系统代码9a0f5b8 · 22 minutes ago1 Commit	
Elasticsearch_database	上传系统代码22 minutes ago
docs	上传系统代码22 minutes ago
graph	上传系统代码22 minutes ago
redis_database	上传系统代码22 minutes ago
.env.example	上传系统代码22 minutes ago
.gitignore	上传系统代码22 minutes ago
.python-version	上传系统代码22 minutes ago
ES_search.py	上传系统代码22 minutes ago
README.md	上传系统代码22 minutes ago
export_architecture.py	上传系统代码22 minutes ago
gradio_background.py	上传系统代码22 minutes ago
gradio_show.py	上传系统代码22 minutes ago
main.py	上传系统代码22 minutes ago
pyproject.toml	上传系统代码22 minutes ago
redis_search.py	上传系统代码22 minutes ago
requirements.txt	上传系统代码22 minutes ago

图 A.1 GitHub 仓库根目录文件列表

详细目录结构说明如表 A.1：

表 A.1 项目根目录文件列表

模块/文件	功能说明
main.py	系统入口，负责启动 Gradio Web 服务
gradio_show.py	前端聊天界面 UI 定义，支持流式输出
gradio_background.py	封装 LangGraph 智能体主逻辑，串联全流程
ES_search.py	Elasticsearch 检索模块，支持 BM25、向量及混合检索
redis_search.py	Redis 缓存模块，实现问答结果缓存与快速响应
export_architecture.py	导出 LangGraph 工作流拓扑图
requirements.txt	Python 项目依赖包列表
.env.example	环境变量配置模板（含 LLM、数据库连接信息）
Graph 文件	LangGraph 编排核心模块
Elasticsearch_database 文件	药典知识库及数据入库脚本
redis_database 文件	Redis 缓存模块
docs 文件	架构图等项目文档资源

附录 A.2 项目文件树与核心模块说明

项目的文件层级与各模块的功能划分如图 A.2 所示，通过该结构可清晰看出系统的分层设计：

```

LangGraph-RAG-Medical-Agent-WangShilin/
├── main.py                # 入口：启动 Gradio Web
├── gradio_show.py         # Gradio UI 定义
├── gradio_background.py   # MedicalChatSystem: 包装 LangGraph 状态图
├── ES_search.py           # 运行时检索模块 (BM25 / Embedding / Hybrid / Weighted)
├── redis_search.py        # 运行时 Redis 缓存读写
├── export_architecture.py # 导出 LangGraph 拓扑为 PNG / Mermaid
├── requirements.txt       # Python 依赖
├── pyproject.toml         # 项目元信息
├── .env.example           # 环境变量模板
├── .gitignore
├── graph/                 # LangGraph 编排层
│   ├── __init__.py
│   ├── build.py           # 装配节点 + 边 + 编译
│   ├── nodes.py           # 节点: cache_lookup / intent_route / rewrite / retrieve / generate ...
│   ├── router.py          # 条件边判定: 意图分流 / 检索回退
│   └── state.py           # GraphState: 节点共享状态
├── Elasticsearch_database/ # 数据建库脚本 + 主知识库
│   ├── ES_search.py       # 建索引 + 字段映射 + 向量化 + 批量入库
│   └── medical.json        # 主医疗知识库 (≈58 MB, 药典)
├── redis_database/
│   └── redis_search.py     # Redis 连通性测试 + 演示数据预热
├── docs/
│   ├── architecture.png   # 架构图
│   └── architecture.mmd   # 架构图 Mermaid 源码

```

图 A.2 项目文件树与模块功能说明

各核心模块的详细功能如表 A.2：

表 A. 2 项目文件树与模块功能说明

模块层级	文件夹/文件	功能说明
LangGraph 编排层	graph/state.py	定义全局状态，存储用户输入、检索结果、历史对话等信息
	graph/nodes.py	实现所有业务节点，包括缓存查询、意图路由、问句改写、混合检索、回答生成等
	graph/router.py	控制节点跳转逻辑，实现意图分流、检索重试等条件分支
	graph/build.py	组装节点与边，编译 LangGraph 工作流
知识库检索 层	Elasticsearch_database/medical.json	存储《中国药典》结构化医疗知识数据
	Elasticsearch_database/ES_search.py	负责数据入库、索引创建、向量生成与批量导入，提供医疗知识检索能力
缓存管理层	redis_database/redis_search.py	实现 Redis 连接与缓存读写，缓存高频问答，降低 LLM 调用成本，提升响应速度
交互层	main.py、gradio_show.py 等	基于 Gradio 构建 Web 聊天界面，提供用户交互、对话历史、流式回答输出